

Fundação Getulio Vargas  
Escola de Matemática Aplicada (EMAp)

Nome: Lucas Machado Moschen

Data: 14 de maio de 2019

Professor Antônio Branco

#### Aula Prática 4

**Exercício 1:** Nesse exercício, represento os anos com início em 0, isto é, 1920 representa 0, 1930, 10 e assim por diante.  $A = [1,0; 1,10; 1,20; 1,30; 1,40; 1,50; 1,60; 1,70]$  e  $b = [54.1; 59.7; 62.9; 68.2; 69.7; 70.8; 73.7; 75.4]$ . Encontro as matrizes  $A^T A$  e  $A^T b$ , para, então, resolver o sistema linear com o método Gaussian\_Elimination  $A^T A x = A^T b$

```
Scilab 6.0.2 Console
--> A = [1,0;1,10;1,20;1,30;1,40; 1,50; 1,60; 1,70]
A =

    1.    0.
    1.   10.
    1.   20.
    1.   30.
    1.   40.
    1.   50.
    1.   60.
    1.   70.

--> b = [54.1;59.7;62.9;68.2;69.7;70.8;73.7;75.4]
b =

    54.1
    59.7
    62.9
    68.2
    69.7
    70.8
    73.7
    75.4

--> S = A'*A
S =

    8.    280.
   280.  14000.

--> c = A'*b
c =

    534.5
   19929.
```

- a) A reta é  $y = 56.633 \dots + 0.290833x$  e com essa reta, a previsão da expectativa de vida é 79.9anos.

```
--> x = Gaussian_Elimination_4(S,c)
x =

    56.633333
    0.290833

--> expectativa_2000 = [1,80]*x
expectativa_2000 =

    79.9
```

- b) A real expectativa de vida em 2000 é 76,64 anos segundo o Banco Mundial, então, a reta não caracteriza bem esses dados. Porém, posso analisar o vetor erro.
- $\|e\| = \|Ax - b\| \approx 4,68$ . Apesar do erro ser um número pequeno, ele não é preciso como forma de previsão, visto que o crescimento da expectativa não é linear.

**Exercício 2:** Inicialmente, tenho as matrizes  $A = [1,0.5,0.25; 1,1,1; 1,1.5,2.25; 1,2,4; 1,3,9]$  e  $b = [11; 17; 21; 23; 18]$ . Encontro as matrizes  $A^T A$  e  $A^T b$ , para, então, resolver o sistema linear com o método Gaussian\_Elimination  $A^T A x = A^T b$ .

- a) A aproximação quadrática é  $s(t) = 1.92 + 20.31t - 4.97t^2$

```
--> x = Gaussian_Elimination_4(S,c)
x =

    1.9175258
    20.306333
   -4.9720177
```

```
Scilab 6.0.2 Console
--> A = [1,0.5,0.25;1,1,1;1,1.5,2.25;1,2,4;1,3,9]
A =

    1.    0.5    0.25
    1.    1.    1.
    1.    1.5    2.25
    1.    2.    4.
    1.    3.    9.

--> b = [11;17;21;23;18]
b =

    11.
    17.
    21.
    23.
    18.

--> S = A'*A
S =

    5.    8.    16.5
    8.    16.5    39.5
    16.5    39.5    103.125

--> c = A'*b
c =

    90.
   154.
   321.
```

- b) Chegamos em  $s_0 \approx 1,92m$ ,  $v_0 \approx 20,31 m/s$  e  $g \approx -9,94 m/s^2$

- c) O objeto atinge o chão tem o mesmo significado de  $s(t) = 0$ . Isto é, queremos encontrar a raiz positiva do polinômio acima mostrado. Aplicando a fórmula de Bháskara no próprio Scilab encontro um valor aproximadamente de  $t = 4,17s$  para o objeto tocar no chão. É interessante que o vetor  $(1, t, t^2)$  é perpendicular ao vetor  $x$ .

**Exercício 3:** Aplico, inicialmente, a função logaritmo natural em ambos os lados da equação, de forma que torna-se uma resolução de sistema linear e posso utilizar o método dos mínimos quadrados com o nosso modelo de matrizes, assim  $\ln(p(t)) = \ln(c) + kt$ . Também utilizo 1950 como 0.

- a)  $A = [1,0; 1,10; 1,20; 1,30; 1,40; 1,50]$  e  $b = \ln([150;179;203;227;250;281])$ . Basta encontrar as matrizes  $A^T A$  e  $A^T b$ , para, então, resolver o sistema linear com o método Gaussian\_Elimination  $A^T A x = A^T b$ .

```
Scilab 6.0.2 Console
--> A = [1,0;1,10;1,20;1,30;1,40;1,50]
A =

1.   0.
1.  10.
1.  20.
1.  30.
1.  40.
1.  50.

--> b = log([150;179;203;227;250;281])
b =

5.0106353
5.1873858
5.313206
5.42495
5.5214609
5.6383547

--> S = A'*A
S =

6.   150.
150.  5500.

--> c = A'*b
c =

32.095993
823.66265
```

```
--> x = Gaussian_Elimination_4(S,c)
x =

5.0455774
0.0121502
```

Assim encontro que  $c = e^{x(1)} \approx 155.3334$  e  $k \approx 0.0122$ . A taxa de crescimento da população é  $p'(t)$  e  $p'(t) = kce^{kt} = 1.89e^{0.0122t}$

- b) Para estimar a população em 2010, basta calcularmos  $p(60) = e^{x(1)}e^{x(2) \cdot 60} \approx 322.012$  milhões.

**Exercício 4:** Utilizo 1970 como 0.

- a) Com os dados, obtenho as matrizes  $A = [1,0,0; 1,5,25; 1,10,100; 1,15,225; 1,20,400; 1,25,625; 1,30,900; 1,35,1225]$  e  $b = [29.3; 44.7; 143.8; 371.6; 597.5; 1110.8; 1895.6; 2476.6]$ . Encontramos as matrizes  $A^T A$  e  $A^T b$  e resolvemos o sistema linear  $A^T A x = A^T b$ .

```

Scilab 6.0.2 Console

1.  0.  0.
1.  5.  25.
1. 10. 100.
1. 15. 225.
1. 20. 400.
1. 25. 625.
1. 30. 900.
1. 35. 1225.

--> b = [29.3;44.7;143.8;371.6;597.5;1110.8;1895.6;2476.6]
b =

29.3
44.7
143.8
371.6
597.5
1110.8
1895.6
2476.6

--> S = A'*A
S =

8.      140.    3500.
140.    3500.    98000.
3500.    98000.    2922500.

--> c = A'*b
c =

6669.9
190504.5
5772232.5

```

Utilizamos, mais uma vez, a função Gaussian\_Elimination. Daqui, temos que a aproximação quadrática é  $q(x) = -19020.833 - 10.733651x + 2.3350317x^2$

```

--> x = Gaussian_Elimination_4(S,c)
x =

57.0625
-20.334643
2.5886429

```

b) Aqui  $A = [1,0; 1,5; 1,10; 1,15; 1,20; 1,25; 1,30; 1,35]$  e  $b = \ln([29.3; 44.7; 143.8; 371.6; 597.5; 1110.8; 1895.6; 2476.6])$ . Repito o mesmo processo de resolução do exercício anterior.

```

Scilab 6.0.2 Console
A =
1.  0.
1.  5.
1.  10.
1.  15.
1.  20.
1.  25.
1.  30.
1.  35.

--> b = log(b)
b =
3.3775875
3.7999735
4.9684234
5.917818
6.3927543
7.0128358
7.5472907
7.8146419

--> S = A'*A
S =
8.  140.
140. 3500.

--> c = A'*b
c =
46.831325
960.55854

```

A partir disso, calcula-se o vetor  $x$  com o método Gaussian\_Elimination.

```

--> x = Gaussian_Elimination_4(S,c)
x =
3.5037431
0.1342956

```

Logo, a aproximação exponencial é  $p(x) = e^{x(1)}e^{x(2)t} \approx 33.2396e^{0.1343t}$

c) Calculam-se os erros referentes às aproximações quadrática e exponencial. Para calcular o erro da aproximação quadrática, faço  $\|e\| = \|Ax - b\|$ , porém a norma da diferença na aproximação exponencial nos diz pouco, visto que  $b = \ln(p(t))$  e  $Ax = \ln(c) + kt$ . Assim,  $\|e\| = \|\exp(Ax) - \exp(b)\|$ , onde estaremos usando  $b$  em sua devida escala e  $\exp(Ax)$  a sua real previsão com o modelo. Como a aproximação quadrática tem erro menor, considero ela uma melhor aproximação. Uso linha para aproximação quadrática.

```

--> e1 = norm(A*x - b)
e1 =
0.739867

--> e2 = norm(Alinha*xlinha - blinha)
e2 =
174.19173

--> e1_corrigido = norm(exp(A*x) - exp(b))
e1_corrigido =
1201.5096

```

d) As previsões para 2010 e 2015 são, respectivamente, utilizando a aproximação quadrática porque ela é uma melhor aproximação,  $q(40) = ([1,40,1600] \cdot x)_{11} = 3385.505$  e  $q(45) = ([1,45,2025] \cdot x)_{11} = 4384.005$  milhares de dólares, em média.

**Exercício 5:** Inicialmente leio esse arquivo csv no Scilab e aplico o método conhecido para encontrar os parâmetros do hiperplano.

```
Scilab 6.0.2 Console
--> Train = csvRead("cancer_train.csv")
Train =

      column 1 to 9

0.64    0.2643  0.6515  0.4006  0.8182  0.8037  0.7031  0.7311  0.7957
0.7318  0.4524  0.705  0.5306  0.5856  0.2277  0.2036  0.3488  0.5961
0.7005  0.541  0.6897  0.4814  0.7574  0.4629  0.4625  0.6357  0.6806
0.4063  0.5188  0.4116  0.1545  0.9848  0.8219  0.5656  0.5229  0.8543
0.7218  0.3651  0.7167  0.519  0.6932  0.3845  0.4639  0.5184  0.5951
0.4429  0.3997  0.438  0.1909  0.8832  0.4922  0.3697  0.402  0.6865
0.6492  0.5087  0.6345  0.4162  0.654  0.3156  0.2641  0.3678  0.5901
0.4877  0.5303  0.4785  0.2313  0.8217  0.4763  0.2194  0.2975  0.7224
0.4625  0.5555  0.4642  0.208  0.8798  0.5594  0.4356  0.4649  0.773
0.4433  0.612  0.4455  0.1904  0.8196  0.6937  0.5326  0.4246  0.6678
0.5699  0.5916  0.5448  0.3192  0.5671  0.1931  0.0773  0.1652  0.5026
0.5614  0.4554  0.5496  0.3125  0.671  0.3741  0.2332  0.3283  0.6059
0.682  0.6314  0.7024  0.4494  0.6731  0.7116  0.4838  0.5557  0.7885
0.5639  0.6097  0.5501  0.3132  0.5806  0.2901  0.2328  0.2666  0.6076
0.4884  0.5756  0.4966  0.2314  0.7816  0.6639  0.4986  0.3989  0.6806
0.5173  0.7011  0.5132  0.2636  0.7871  0.4618  0.384  0.366  0.7576
0.5222  0.5125  0.5026  0.2739  0.6819  0.2085  0.1733  0.2614  0.5217
0.5738  0.5265  0.5735  0.3196  0.8086  0.5854  0.4035  0.5109  0.7118
0.7047  0.5639  0.6897  0.5042  0.6794  0.2873  0.3465  0.4721  0.5204
0.4817  0.3656  0.464  0.2266  0.6758  0.2354  0.1561  0.2376  0.6201
0.4653  0.3999  0.4543  0.2081  0.7429  0.3677  0.107  0.1546  0.647
0.3381  0.3167  0.3201  0.1096  0.7077  0.188  0.0693  0.1032  0.597
0.5457  0.363  0.5438  0.2819  0.7415  0.6181  0.4866  0.4849  0.8293
0.7528  0.5866  0.7279  0.5618  0.6516  0.2959  0.257  0.429  0.5819
0.5923  0.5443  0.5836  0.362  0.7747  0.4218  0.3573  0.4558  0.6563
0.6097  0.4175  0.6154  0.3652  0.8196  0.6589  0.5223  0.6963  1.
0.5187  0.5481  0.5168  0.258  0.7284  0.5408  0.3339  0.4365  0.7408
0.662  0.5155  0.6477  0.4378  0.6524  0.3086  0.3491  0.3842  0.5582
0.5443  0.6433  0.5432  0.2931  0.7478  0.4913  0.3943  0.4349  0.6336
0.625  0.3831  0.6101  0.3822  0.6805  0.335  0.2314  0.3953  0.572
0.6628  0.6393  0.6621  0.4354  0.7353  0.5463  0.5433  0.6183  0.7181
```

```
Scilab 6.0.2 Console
--> S = A'*A
S =

      column 1 to 7

300.    154.141  147.5548  150.0015  82.0813  203.1371  96.269
154.141  83.966305  77.525382  81.963232  47.467449  104.77098  52.478042
147.5548  77.525382  76.132807  75.562809  42.228591  99.965872  48.967562
150.0015  81.963232  75.562809  80.046643  46.477097  102.13569  51.596091
82.0813  47.467449  42.228591  46.477097  28.479059  56.057643  29.632482
203.1371  104.77098  99.965872  102.13569  56.057643  140.2849  68.176907
96.269  52.478042  48.967562  51.596091  29.632482  68.176907  38.899619
70.    40.579645  36.521385  40.079624  24.386751  50.351289  30.851984
81.1051  47.50576  42.127761  46.806794  28.705552  57.999954  34.02661
182.5533  94.309236  90.049635  91.9514  50.489161  125.14329  61.475012
193.7372  98.655056  95.15013  96.122647  52.089901  132.48735  64.342993

      column 8 to 11

70.    81.1051  182.5533  193.7372
40.579645  47.50576  94.309236  98.655056
36.521385  42.127761  90.049635  95.15013
40.079624  46.806794  91.9514  96.122647
24.386751  28.705552  50.489161  52.089901
50.351289  57.999954  125.14329  132.48735
30.851984  34.02661  61.475012  64.342993
27.571073  29.145927  45.502713  46.997318
29.145927  33.203387  52.095687  53.300484
45.502713  52.095687  113.83674  118.95237
46.997318  53.300484  118.95237  126.84905
```

```
--> c = A'*b
c =

-8.
22.3732
11.9498
23.7317
26.1507
4.3607
25.6336
34.4296
40.4757
3.7953
-5.1184
```

Encontro os 11 parâmetros, então, representados como coordenadas do vetor  $x$ .  $c_0 = x(I)$  e assim por diante.

```
--> x = Gaussian_Elimination_4(S,c)
x =

-6.7579731
 29.311052
  2.0765803
-18.730222
-7.3665161
  1.2222756
  0.2283419
  0.0503253
  2.2385058
  0.0249405
  0.7704282
```

- a) Vou calcular a porcentagem sobre o arquivo de treinamento, a fim de obter uma medida de capacidade de generalização do modelo. Para isso, realizo o produto  $Ax \cdot b$  que faz o produto índice a índice. Se o resultado der positivo, é porque o modelo acertou, se der negativo, porque o modelo errou.

$$comparing = (Ax) \cdot b$$

$$percent = size(find(comparing \geq 0), 2) / size(comparing, 2) = 0.93 = 93\%, \text{ taxa de acerto.}$$

- b) Agora, calculemos a porcentagem de acerto sobre os dados na planilha de teste. Capturam-se os dados da planilha cancer\_test e dispomos numa matriz T. Obtemos as previsões com o vetor Tx e para calcular a porcentagem, fazemos como no item anterior.

```
Scilab 6.0.2 Console
--> T = zeros(260,11); T(:,1) = ones(260,1); T(:,2:11) = Test(:,1:10)
T =

column 1 to 10

1.  0.7123  0.6152  0.6929  0.4866  0.7038  0.6374  0.6044  0.5551  0.6975
1.  0.4544  0.6475  0.4303  0.1884  0.5172  0.3936  0.1879  0.162  0.6933
1.  0.7327  0.7767  0.7207  0.4986  0.661  0.7135  0.6281  0.6691  0.8754
1.  0.3026  0.6088  0.3977  0.1337  0.6336  0.2892  0.0632  0.093  0.8769
1.  0.4179  0.5911  0.3937  0.1612  0.6418  0.2997  0.092  0.0785  0.8492
1.  0.423  0.7972  0.3972  0.1668  0.4574  0.2208  0.0543  0.0686  0.7532
1.  0.4914  0.515  0.4458  0.2148  0.5209  0.2038  0.004  0.017  0.6353
1.  0.3282  0.4688  0.3016  0.0985  0.4287  0.121  0.0101  0.0181  0.696
1.  0.4923  0.4137  0.4585  0.2264  0.4514  0.1403  0.0076  0.0231  0.5313
1.  0.4759  0.4505  0.4425  0.2122  0.5111  0.145  0.0125  0.0462  0.5656
1.  0.4267  0.6221  0.3977  0.1674  0.5394  0.2039  0.0435  0.06  0.7536
1.  0.5328  0.5107  0.4959  0.2659  0.4662  0.1365  0.0358  0.0981  0.6353
1.  0.4654  0.4252  0.4408  0.2015  0.5392  0.3085  0.1115  0.1322  0.6282
1.  0.4205  0.349  0.3945  0.1536  0.5261  0.2317  0.0376  0.0466  0.7135
1.  0.3135  0.6055  0.2894  0.0884  0.6573  0.227  0.  0.  0.842
1.  0.4555  0.5485  0.4237  0.1926  0.5209  0.1488  0.0123  0.0336  0.4729
1.  0.4442  0.4583  0.4133  0.1845  0.4733  0.1247  0.0309  0.0264  0.6512
1.  0.6645  0.6143  0.6351  0.4106  0.5965  0.4336  0.3109  0.4156  0.7034
1.  0.3298  0.6152  0.3214  0.0978  0.61  0.7655  0.5433  0.2566  0.907
1.  0.4533  0.5534  0.4205  0.1908  0.4625  0.1341  0.0369  0.0888  0.573
1.  0.3738  0.5267  0.3659  0.1256  0.6493  0.4313  0.105  0.2073  0.6785
1.  0.2952  0.64  0.7014  0.5094  0.4508  0.3255  0.2177  0.4039  0.7605
1.  0.465  0.4236  0.4421  0.2018  0.594  0.3425  0.1045  0.1777  0.6006
1.  0.7418  0.7002  0.7271  0.5054  0.715  0.7279  0.7056  0.7862  1.
1.  0.4449  0.4951  0.4174  0.1831  0.5308  0.2541  0.0549  0.0884  0.6376
1.  0.4621  0.5632  0.4347  0.1959  0.6291  0.2975  0.0878  0.1101  0.6645
1.  0.5146  0.4193  0.4817  0.2465  0.5697  0.206  0.0486  0.1425  0.5344
1.  0.4387  0.5837  0.4071  0.1783  0.4702  0.1511  0.0043  0.0292  0.538
1.  0.5934  0.6742  0.572  0.3253  0.7154  0.512  0.4066  0.4437  0.7583
1.  0.599  0.7122  0.5762  0.3206  0.713  0.4981  0.4949  0.4172  0.7275
```

```

Scilab 6.0.2 Console
--> prev = T*x
prev =
1.6584775
0.0722914
2.282382
-0.3554046
-0.4181851
-0.1147566
-0.3737789
-1.3794416
-0.6462502
-0.5046754
-0.2870478
-0.0663594
-0.4032174
-0.5796701
-0.914929
-0.4078044
-0.7482074
1.3219255
-0.3057896
-0.3453685
-0.3604922
1.2552196
-0.03089
2.4956079
-0.4396696
-0.0431002
-0.1043287
-0.4490484
1.4542401
1.3811876
0.6561039
0.1560214
-0.3300141
-0.8321871

```

$$comparing = (Tx) \cdot b$$

$percent = size(find(comparing \geq 0), 2) / size(comparing, 2) = 0.7115 = 71.15\%$ , taxa de acerto. De fato a taxa foi menor do que eu esperava e a nível geral não é um bom preditor, porém é melhor do que um randômico.

Por fim, vejamos a porcentagem de falsos positivo e negativo e verdadeiros positivo e negativo na tabela “cancer\_train”, baseado no nosso hiperplano. Criei uma matriz de comparing com os dados da real presença ou ausência da doença e uma terceira coluna com sua classificação.

```

--> comparing(50:70, :)
ans =
-1.  -1.  4.
-1.  -1.  4.
1.   1.  1.
1.   1.  1.
1.   1.  1.
-1.  -1.  4.
-1.   1.  3.
-1.   1.  3.
-1.  -1.  4.
-1.  -1.  4.
-1.  -1.  4.
-1.   1.  3.
-1.   1.  3.
-1.   1.  3.
-1.  -1.  4.
1.   1.  1.
1.   1.  1.
-1.  -1.  4.
1.   1.  1.
1.   1.  1.

```

Defini: 1 = Verdadeiro Positivo, 2 = Falso Negativo (teste negativo e presença da doença), 3 = Falso Positivo (teste positivo e ausência da doença) e 4 = Verdadeiro Negativo. Calculam-se, as porcentagens de cada tipo:



```
--> porcentagens
porcentagens =

  0.2307692  0.  0.2884615  0.4807692
```

Assim:

Taxa de verdadeiro positivo: 23.08%

Taxa de verdadeiro negativo: 48.08%

Taxa de falso positivo: 28.84%

Taxa de falso negativo: 0%